

Bối cảnh & pain point

400k MAU

nền tảng Toán & Khoa học của EduNova

Học sinh 11–16

cấp 2, dùng chủ yếu trên mobile


Gap hiện tại

lời giải sẵn không dạy cách suy luận — kẹt bài → bỏ cuộc

TutorMate dẫn dắt học sinh đi tới đáp án — thay vì đưa đáp án.

AI-First: bỏ AI đi thì không còn “gia sư” — chỉ còn app trắc nghiệm cũ. Toàn bộ giá trị mới nằm ở vòng lặp bên phải.

Vòng lặp giá trị



TutorMate ≠ ChatGPT + prompt

ChatGPT / chatbot generic	TutorMate	Cơ chế trong kiến trúc
Mục đích chung	Gia sư Toán/Khoa học có phạm vi (domain-locked)	Input Guard + topic classifier chặn ngoài phạm vi
Tối ưu để TRẢ LỜI	Tối ưu để HỌC — câu hỏi kế tiếp, hé lộ tối thiểu	Dialogue Policy quyết định action; LLM chỉ diễn đạt
Kiến thức chung của model	Grounding trên chương trình đã duyệt (Hint Ladder)	RAG trên corpus giáo viên duyệt, có version
Điều khiển bằng prompt	Tutoring state machine tường minh	Orient→Elicit→Hint→Check→Consolidate→Escalate (ADR-001)
Output đi thẳng từ model	Output được VALIDATE trước khi tới học sinh	Response Validator: safety · leak · grounding · age (ADR-004)



Kiến trúc mục tiêu: LLM không phải policy engine

Nguyên tắc

- Orchestrator sở hữu state
- Tools xử lý phần cần chính xác
- RAG ground câu trả lời
- Validator là cổng cuối trước trả em



Async (Kafka)

- Telemetry / events
- Evaluation sampling (LLM-judge + giáo viên)
- Monitoring · alert
- Cost tracking / turn
- Learner model update

Nền tảng

AWS · EKS (stateless, HPA/KEDA) · Aurora Postgres + pgvector · ElastiCache Redis · MSK Kafka · S3 · Bedrock/OpenAI qua LiteLLM gateway

Chi tiết: [Appendix B](#)

C4 L1–L3 đầy đủ: ATAD §2
Chỉ có ~10 box: mỗi box có 1 lý do tồn tại

Pedagogy được enforce · Personalization có giới hạn

Rubric 4.1 · 4.4

Socratic state machine (Dialogue Policy)



- Hint level +1 CHỈ sau ≥ 2 lỗi khác nhau (CAS chấm) — rule trong code, không trong prompt
- Escalate (reveal có điều kiện / chuyển giáo viên) chỉ khi hết ladder hoặc cờ an toàn
- LLM nhận: action + ladder ≤ level hiện tại + 6 lượt gần nhất → chỉ diễn đạt

Ví dụ

Học sinh: $2x + 5 = 15$ — “em không biết làm”

x Chatbot: $x = 5$

✓ **TutorMate (Elicit):** “Em nghĩ bước đầu tiên nên làm gì để bỏ +5 ở vế trái?”

→ Sai lần 1 (“chia cho 2”): Check → misconception ‘thứ tự phép toán’ → Hint L1, chưa lộ bước

→ Đúng: Consolidate — “Vì sao trừ 5 cả hai vế vẫn giữ đẳng thức?” rồi cập nhật mastery

Learner profile — lưu gì / không lưu gì

LƯU (tín hiệu học tập có giới hạn)	KHÔNG LƯU mặc định
P(mastery)/skill — BKT, pseudonymous ID	Transcript đầy đủ dài hạn (redacted raw: 30 ngày rồi xoá)
Loại lỗi gần nhất (misconception tag)	Danh tính thật của trẻ trong prompt (chỉ token)
Lịch sử hint level / skill	Hồ sơ tâm lý, cảm xúc, hành vi ngoài học tập
Độ tự tin (self-report, tùy chọn)	Vị trí, thiết bị, contact phụ huynh trong learner store
profile_version + consent_version	Dữ liệu dùng để train khi chưa có consent riêng

- Cá nhân hoá = chọn skill/bài kế tiếp, độ khó, mức hint khởi điểm — từ vector mastery
- Học sinh / phụ huynh xem & reset profile; xoá theo yêu cầu ≤ 30 ngày (ADR-002, §5.7)

Personalization dựa trên tín hiệu học tập có giới hạn (bounded learning signals) — không phải bộ nhớ không giới hạn.

Vì sao Hybrid: RAG + LLM + Tools — curriculum grounding

Pattern chọn:

Hybrid tutoring architecture — dùng LLM chỉ ở nơi bài toán thực sự là ngôn

Capability	Pattern công nghệ	Vì sao không để LLM làm
Diễn đạt gợi mở tự nhiên	LLM (managed small, T1)	— đây là phần ngôn ngữ thật
Curriculum grounding	RAG trên Hint Ladder giáo viên duyệt	Model không biết SGK/chương trình EduNova; cần version & audit
Đúng/sai, tương đương công thức	Deterministic tool (CAS/SymPy)	LLM tính toán không tin được; 0 chi phí token
Cập nhật mastery	Deterministic logic (BKT)	Cần giải thích được, ổn định, audit
Kiểm soát sự phạm	State machine (Dialogue Policy)	Prompt không enforce được; code unit-test được
Safety / answer-leak	Validator (rule + classifier + safety API)	Không để model tự chấm chính mình

Vì sao không fine-tune trước?

Chưa có corpus hội thoại gia sư đáng tin (~0) + chương trình đổi thường xuyên → RAG cập nhật được, FT thì phải train lại.
FT/DPO 8B là Phase 2 khi ≥ 50k lượt có nhãn (ADR-005).

Vì sao không autonomous agent?

Không cần autonomy — flow gia sư là hữu hạn; agent làm tăng latency, cost và bề mặt rủi ro an toàn.

Curriculum grounding — offline lane



Dùng LLM chỉ ở nơi bài toán thực sự là ngôn ngữ; grounding = corpus đã duyệt, không phải trí nhớ của model.

An toàn cho trẻ em: 4 lớp phòng thủ

1 • TRƯỚC MODEL

Identity · parental consent gate · input moderation · prompt-injection detection · topic lock

2 • TRONG KHI DẠY

Bounded tools · retrieval chỉ corpus đã duyệt · state policy · token/turn budget · không có đáp án trong context

3 • TRƯỚC KHI GỬI

Validator: safety · grounding · age-appropriate · answer-leak (CAS vs Vault + paraphrase clf) → fail = hint tĩnh

4 • SAU KHI GỬI

Monitoring · red-team liên tục · canary/rollback 5' · kill-switch → Static Ladder Mode

OUTPUT CHƯA VALIDATE KHÔNG BAO GIỜ TỚI HỌC SINH

2 rủi ro quan trọng nhất

Rủi ro	Kiểm soát	Target
Harmful content (self-harm, bạo lực, người lớn, grooming)	Lớp 1 + 3: classifier + managed safety API; self-harm → protocol dừng dạy, đưa hotline, báo phụ huynh	0 pass-through red-team · < 0.01% prod
Answer leakage (“cho đáp án đi”, jailbreak, paraphrase)	State machine + canonical answer check (CAS) + leak classifier + adversarial eval mỗi release	ALR ≤ 1.0% golden set · ≤ 0.5% production

- Dữ liệu tối thiểu: pseudonymous, raw redacted 30 ngày, không train khi chưa consent
- Bias/fairness: đo ALR & pedagogy score theo nhóm (giới, vùng, gói free/paid)
- XAI: mỗi hint có trace → ladder version · policy state · validator verdict

Governance map: NIST AI RMF · ISO/IEC 42001 · Nghị định 13/2023 (PDP VN) · COPPA/GDPR-K nếu mở rộng — yêu cầu pháp lý theo từng thị trường vẫn là ASSUMPTION cần legal xác nhận (ATAD §11).


Evaluation: làm sao biết TutorMate “dạy tốt”?

Chiều đo	Metric	Cách đo	Ngưỡng release
Correctness	Đúng đáp án / đúng từng bước	CAS + golden set	≥ 98% grader accuracy
Grounding	Hint có nguồn hợp lệ trong ladder	Citation check	≥ 97%
Pedagogy	State adherence · hint usefulness (Pedagogy Score)	LLM-judge calibrated với giáo viên ($\kappa \geq 0.7$)	≥ 4.0/5
Leakage	Answer Leak Rate (ALR)	CAS vs Vault + clf, adversarial set	≤ 1.0% golden · ≤ 0.5% prod
Safety	Critical escape · false refusal	Red-team suite 300+ case	0 escape · FR < 3%
Adaptation	Mastery update đúng hướng	Offline replay BKT	AUC ≥ 0.75
Performance	Latency full-turn	Load test + prod	p95 < 3s
Cost	Cost / turn blended	Gateway ledger	≤ \$0.0007

RELEASE GATE: quality + safety + latency + cost — PHẢI ĐẠT CẢ 4 mới được promote (shadow → 5% → 25% → 50% → 100%)

- Outcome thật (không proxy): bỏ dở 35% → ≤ 22% · đúng cùng skill ngày hôm sau 48% → ≥ 60% · Free→Paid 5% → ≥ 7% — đo A/B trong prod

Bộ dữ liệu & quy trình




Performance & Scale: p95 < 3s và chịu 5–8× peak

Tải (turns/s)

Mức	Turns/s
Trung bình (960k/ngày)	≈ 11
5× peak	≈ 56
8× peak (design target)	≈ 89
10× load test	≈ 111

[A] 30% DAU dùng tutor × 8 lượt; đo lại ở beta 2k HS. Peak = 19–22h ngày thi.

Chiến lược scale



Latency budget (p95 < 3s)

Bước	Budget
Policy · profile · retrieval · guard-in	< 0.7s
LLM generation (T1, ~120 tokens)	1.5–1.8s
Validation + network mobile	< 0.5s
Headroom	≈ 0.2–0.4s

- Streaming token đầu < 1s để cảm nhận nhanh
- 12% lượt không gọi LLM (CAS đúng → hint tĩnh)
- Staging mô phỏng p95 ≈ 2.6s — là BUDGET kiến trúc, chưa phải benchmark đo thật

Bottleneck đầu tiên kỳ vọng: concurrency / latency của model provider — không phải tầng API stateless → tiering + fallback + provisioned throughput.

- Degrade có kiểm soát: provider lỗi → T2 provider 2 → Static Ladder Mode (SLO tutor 99.5% tính cả degraded; LLM-mode 99.0%)
- Vendor-neutral: Kubernetes · Postgres · Kafka · S3-API · LiteLLM — đổi cloud/provider không đổi ứng dụng

Phương trình chi phí

Monthly AI cost = turn volume × cost/turn + shared infra

$\approx 29\text{M lượt} \times \$0.00069 \approx \$18.4\text{k/tháng AI} \cdot + \text{infra} \approx \$11\text{k} \cdot \text{budget} = 8.000 \times P \rightarrow P \geq \sim \2.30

#	Cost driver	Cơ chế kiểm soát
1	LLM tokens (prompt + history + output)	Model tiering T1/T2 · context limit · prompt cache · 12% lượt không gọi LLM
2	Moderation / safety API	Rule + classifier nhỏ trước, API chỉ backstop
3	Retrieval / embeddings	Embed offline 1 lần/ladder version · cache theo bài
4	Retries / fallback / judge	Turn budget · judge sampling 5% · fallback T2 có quota
5	Infrastructure	Spot cho batch · autoscale to zero ngoài giờ · managed services

Free tier: quota 20 lượt/ngày; paid không giới hạn · cost alert 80% / kill 120% budget ngày · [A] giá provider & mix trả phí 10% (sens. 5/15%) cần cập nhật hàng tuần

Production operations

Model Gateway fallback

T1 → T2 → provider 2 → Static Ladder Mode

Release manifest

model + prompt + ladder + policy version, ký & lưu

Canary rollout

shadow → 5% → 25% → 50% → 100%, gate 4 điều kiện

Rollback ≤ 5 phút

đảo alias / prompt pointer, không redeploy

Kill switch

tắt LLM-mode toàn cục hoặc theo cohort

Cost & drift alerts

ledger / turn · ALR · judge score theo ngày

- MLOps/LLMOps: eval CI trên golden set mỗi PR prompt/ladder · registry version · audit log
- On-call runbook: leak spike, provider outage, harmful escape, cost spike

Production-ready = fail an toàn, degrade có kiểm soát, và luôn nằm trong budget.

5 quyết định kiến trúc panel cần nhớ

1

Hybrid AI, không phải prompt-only

LLM chỉ sinh ngôn ngữ; RAG + CAS + BKT + state machine làm phần còn lại (ADR-003, -005)

2

Socratic state machine tường minh

Policy quyết định hé lộ; hint level là code, test được (ADR-001)

3

Learner profile tối thiểu

P(mastery)/skill pseudonymous; không transcript dài hạn, không PII trong prompt (ADR-002)

4

Safety + validation TRƯỚC khi gửi

4 lớp phòng thủ; LLM không nhận đáp án; output chưa validate không tới trẻ (ADR-004)

5

Eval-gated, scalable, cost-controlled

Release gate 4 điều kiện · stateless autoscale · tiering + quota $\leq \$0.0007/\text{lượt}$

TutorMate không chỉ là một LLM chatbot. Đó là một nền tảng gia sư AI được kiểm soát — an toàn cho trẻ em, đo được, và vận hành được ở quy mô.

Team ownership: Thuận (Req & Integration) · Huyền (Logical & Data) · Hòa (AI/ML) · Phụng (Responsible AI) · Bình (Cloud & Scale) · Phú (Eval & Cost) · Dũng (Slides & Q&A) — Q&A do Dũng điều phối; chi tiết phân công: Appendix D & ATAD

Appendix A · Technology Selection Matrix

Pattern	Phù hợp	Cold-start (~0 dialogue)	Kiểm soát lộ đáp án	Latency/Cost	Quyết định
Pure RAG + prompt	Trung bình	Tốt	Yếu (prompt-only)	Tốt	✗ không đủ enforce
Fine-tune trước	Cao (nếu có data)	Không có data	Trung bình	Tốt (self-host)	✗ Phase 2 (D-04)
Autonomous agent	Thấp	Tốt	Yếu, khó audit	Kém	✗
Hybrid: policy + RAG + tools + LLM	Cao	Tốt (ladder tổng hợp)	Mạnh (least-privilege)	Tốt	✓ Accepted (ADR-003)

Lớp	Ứng viên	Chọn MVP	Lý do
Runtime LLM (T1)	GPT-4o-mini · Claude Haiku · Gemini Flash · Llama 8B self-host	Managed small model qua LiteLLM, 2 provider	Latency, cost, không cần GPU ops sớm; self-host khi ≥ 50k lượt nhấn
Offline LLM (T3)	GPT-4o · Claude Sonnet · Gemini Pro	Frontier cho sinh ladder / judge / synthetic	Chất lượng quan trọng hơn cost, chạy batch
Vector store	pgvector · Pinecone · Weaviate · OpenSearch	Postgres + pgvector (HNSW)	Corpus nhỏ (< 5M chunk), 1 hệ thống, ACID với metadata
Grader	LLM · SymPy/CAS · Wolfram	SymPy + rule	Deterministic, miễn phí, giải thích được
Learner model	BKT · DKT (deep) · IRT	BKT	Ít data, giải thích được; DKT khi đủ event
Cloud	AWS · GCP · Azure	AWS (EKS, Aurora, MSK, Bedrock)	Đội đã có; portable qua K8s/Postgres/Kafka/S3-API
Gateway	LiteLLM · Portkey · tự viết	LiteLLM	OSS, tiering, fallback, cache, ledger cost

Appendix B · Cloud deployment (AWS, vendor-neutral)

Rubric 4.3

Lớp	Thành phần AWS	Cấu hình MVP → 8× peak	Thay thế (neutral)
Region / HA	ap-southeast-1, 3 AZ	Multi-AZ; DR warm ap-northeast-1 (RPO 15')	Bất kỳ region 3 AZ
Network	VPC private subnets · NAT · PrivateLink tới Bedrock	Egress chỉ qua gateway allowlist	Tương đương mọi cloud
Edge / API	CloudFront · WAF · ALB · API Gateway (WebSocket streaming)	Rate-limit / quota theo user & cohort	Cloud LB + WAF
Compute	EKS (Graviton) · HPA + KEDA (Kafka lag)	Orchestrator 6 → 48 pod · Guard 4 → 32 · Grader 4 → 24	Bất kỳ K8s
State	Aurora PostgreSQL + pgvector · read replica	r7g.xlarge ×2 → ×4; ladder cache Redis	Postgres bất kỳ
Cache / session	ElastiCache Redis cluster	6 shard · TTL phiên 2h	Redis / Valkey
Streaming	MSK (Kafka)	3 broker · topic events/eval/cost	Kafka / Redpanda
Object storage	S3 (ladder versions, transcripts redacted 30d, eval sets)	Lifecycle 30d → glacier / xoá	S3-API bất kỳ
LLM	Bedrock (T1/T2) + OpenAI (fallback) qua LiteLLM	Provisioned throughput cho peak; quota theo tier	Đổi provider = đổi config
Observability	CloudWatch · OpenTelemetry · Grafana · Langfuse-style trace	Trace mỗi turn: policy state · ladder ver · validator verdict	OTel-native
Security	KMS · Secrets Manager · IAM least-privilege · GuardDuty	Vault chỉ Grader/Validator role đọc được	Tương đương

GPU strategy: MVP không sở hữu GPU (managed inference). Phase 2: vLLM trên g6/L4 hoặc Inferentia cho 8B SFT khi đủ dữ liệu — quyết định theo cost/turn thực đo (ADR-005). Chi tiết: ATAD §2.3, §10.

Appendix C · Risk Register (top 8)

ID	Rủi ro	L	I	Kiểm soát chính	Owner
R-01	Lộ đáp án qua jailbreak / paraphrase	M	H	LLM không nhận Vault · CAS-leak check · leak clf · adversarial eval mỗi release	Phụng
R-02	Nội dung có hại tới trẻ (self-harm, grooming)	L	Rất H	3 lớp guard · self-harm protocol · 0 red-team escape gate	Phụng
R-03	Hint sai kiến thức / lệch chương trình	M	H	Ladder giáo viên duyệt · CAS · grounding check ≥ 97%	Hòa
R-04	Vi phạm dữ liệu trẻ em (consent, retention)	L	Rất H	Consent gate · pseudonymous · 30d retention · DPIA	Phụng
R-05	Provider LLM outage / latency spike	M	M	2 provider · provisioned throughput · Static Ladder Mode	Bình
R-06	Peak 8× vượt dự báo	M	M	HPA/KEDA · quota free · load test 10×	Bình
R-07	Cost vượt trần 20% doanh thu	M	M	Tiering · cache · quota · alert 80% / kill 120%	Phú
R-08	Cold-start: ladder tổng hợp kém, học sinh không dùng	M	H	Beta 2k HS · giáo viên duyệt · KPI abandonment theo tuần	Hòa

L = likelihood · I = impact. Review 2 tuần/lần; R-01/R-02 có KRI theo ngày (ALR, escape count). Full register 15 mục + threat model prompt-injection: ATAD §8, §11.5.

Appendix D · Requirement · Assumption · Proposal

[R] Requirement = đề bài workshop đưa, không thương lượng · [A] Working assumption = nhóm giả định, xác nhận ở beta · [P] Architect proposal = nhóm đề xuất, có ADR · [D] Data/training prerequisite = điều kiện bắt một thành phần

Loại	Phát biểu	Nguồn / cách xác nhận	Owner
[R] Requirement	p95 latency < 3s toàn lượt	Đề bài Scenario B	Bình
[R] Requirement	Chịu 5–8× peak; không lộ đáp án trực tiếp; consent phụ huynh; freemium	Đề bài Scenario B	Thuận
[A] Assumption	30% DAU dùng tutor × 8 lượt → 960k lượt/ngày, 29M/tháng	Đo ở beta 2k HS; cập nhật cost model tuần	Phú
[A] Assumption	Thị trường chính Việt Nam (Nghị định 13); mix trả phí 10% (sens. 5/15%)	Legal + finance xác nhận	Phụng
[A] Assumption	Managed small model đủ chất lượng Socratic khi có ladder + policy	Golden set ≥ 1,000, Pedagogy ≥ 4.0/5 ở beta	Hòa
[P] Proposal	ALR ≤ 1.0% golden · ≤ 0.5% prod · golden set ≥ 1,000 · release gate 4 điều kiện	ADR-001/-004; panel có thể thách thức ngưỡng	Phụng
[P] Proposal	Hybrid policy + RAG + tools + managed LLM; AWS + pgvector; BKT	ADR-001....-005 (Accepted)	Hòa
[P] Proposal	Cost ≤ \$0.0007/lượt; AI ≤ 20% doanh thu	Cost model §10; đo bằng gateway ledger	Phú
[D] Prerequisite	≥ 50k lượt thật có nhấn trước khi SFT/DPO 8B self-host (Phase 2)	ADR-005 Proposed — chưa bật	Hòa
[D] Prerequisite	Ladder giáo viên duyệt ≥ 80% bài top-traffic trước launch	Offline lane, tracker duyệt	Huyền

Full register 25+ mục: ATAD Appendix E. Mỗi ADR có Status (Accepted / Proposed) và điều kiện kích hoạt — không phát biểu nào được trình bày như 'đã đo trong production'.