

PRESENTATION PLAN — VARIANT B: AI RETROFIT

1. Câu chuyện tổng thể của bài trình bày

Không trình bày sáu artifact như sáu tài liệu độc lập. Hãy nối chúng thành một chuỗi lập luận:

**Constraint → Architecture → Runtime flow → Measurable proof → Decision → Risk
→ Controlled rollout**

Thông điệp trung tâm:

Keep MERLIN in control; let AI fail without stopping a truck.

Nghĩa là:

- Không thay thế MERLIN.
- Không đưa AI vào critical path.
- AI chỉ tạo đề xuất có giới hạn.
- MERLIN vẫn tạo đơn hàng và gửi EDI.
- AI lỗi, trễ, thiếu dữ liệu hoặc bị tắt thì hệ thống đặt hàng hiện tại vẫn hoạt động.

2. Dàn bài 8 slide trong 7 phút

Slide	Nội dung	Artifact liên quan	Thời gian
1	Executive message và nguyên tắc thiết kế	Tổng hợp	30 giây
2	Legacy constraints: được thay đổi gì và không được chạm gì	A6	50 giây
3	C4 Context và Container Architecture	A1	60 giây
4	Nightly batch, deadline và fail-open flow	A1	65 giây
5	NFR, capacity, business target và cost	A2	65 giây
6	Technology-selection matrix và ADR	A3, A4	55 giây
7	Top-five architecture risks	A5	45 giây
8	Rollout, kill switch và kết luận	A6	50 giây
Tổng cộng			420 giây

3. Full presentation script

Script được viết bằng tiếng Anh vì nội dung slide đang sử dụng tiếng Anh. Tốc độ phù hợp là khoảng 120–130 từ/phút.

Slide 1 — Executive message

Thời gian: 30 giây

Good morning.

Our design principle is simple: keep MERLIN in control, and let AI fail without stopping a truck.

We are not replacing MERLIN. We add an external, asynchronous AI sidecar that produces statistical forecasts and bounded deterministic replenishment recommendations. MERLIN still generates every supplier order and remains the only system that sends EDI.

If AI produces no valid output, the existing min-max replenishment process continues unchanged.

Cách trình bày

Nhấn giọng ở ba cụm:

- “not replacing MERLIN”
- “MERLIN still generates every order”
- “AI can fail without stopping delivery”

Không giải thích chi tiết kiến trúc ở slide này. Đây chỉ là executive summary.

Câu chuyển

To understand why we selected this design, we first need to understand what the legacy environment allows us to change.

Slide 2 — Legacy assessment

Thời gian: 50 giây

Variant B begins with constraints, not technology choices.

We can change only the edges: an external sidecar, narrow certified adapters, monitoring, audit and disable controls.

We cannot change the MERLIN engine, its ordering authority, the POS runtime, the supplier EDI schema or the fixed 04:00 cut-off.

We also identified unsafe areas that must not be touched: undocumented tables, internal scheduler hooks, manual rows and point inventory treated as real-time shelf truth.

Therefore, the retrofit uses exactly three supported crossings: the nightly snapshot, the pre-generation override table and the post-generation review queue. We do not invent a fourth interface.

Ý chính cần truyền đạt

Variant B không bắt đầu bằng câu hỏi:

“Chúng ta nên dùng model hoặc cloud service nào?”

Nó bắt đầu bằng câu hỏi:

“Legacy system cho phép chúng ta đi qua những boundary nào?”

Ba interface hợp lệ:

1. **Nightly snapshot:** AI chỉ đọc dữ liệu đã được xuất.
2. **Override table:** AI có thể ghi đề xuất giới hạn trước khi MERLIN chạy.
3. **Review queue:** Sau khi MERLIN tạo đơn, có thể lấy lại thông tin được chứng nhận để audit hoặc review.

“No fourth interface” là một câu quan trọng. Nó thể hiện nhóm không tự tạo API hoặc kết nối không có trong legacy environment.

Câu chuyển

Based on those boundaries, we place AI beside MERLIN rather than inside it.

Slide 3 — C4 context and container

Thời gian: 60 giây

At the context level, MERLIN remains the authoritative ordering system. Category managers continue to use its native review process, and suppliers continue to receive fixed-schema EDI from MERLIN only.

Inside the AI sidecar, the nightly snapshot first passes schema, freshness, completeness, checksum and residency validation. Statistical forecasting then produces demand quantiles and confidence intervals. A deterministic optimizer applies case-pack, shelf-life, inventory-interval, distribution-centre and category constraints.

Only a certified adapter can write bounded current-run rows to the supported override table. MERLIN reads those rows, runs its unchanged engine and generates the order.

There is no AI route to POS, EDI or suppliers. The post-generation return is evidence for correlation and audit, not a runtime dependency.

Khi chỉ vào sơ đồ

Trình bày theo thứ tự từ trái sang phải:

1. Nightly snapshot.
2. Validation.
3. Statistical forecast ML.
4. Deterministic optimizer.
5. Certified adapter.
6. Override table.
7. MERLIN engine.
8. Review queue.
9. EDI và suppliers.

Phân biệt hai khái niệm

Statistical forecast ML

Dự đoán nhu cầu, ví dụ:

- Expected demand.
- Lower and upper quantiles.
- Confidence interval.
- Promotion-related forecast.

Deterministic optimizer

Chuyển forecast thành quantity hợp lệ bằng các luật cố định:

- Whole case packs.
- Shelf-life limit.
- Distribution-centre capacity.
- Category cap.
- Inventory lower and upper bounds.

AI model không trực tiếp “quyết định đơn hàng”. Model chỉ forecast; deterministic logic mới tạo candidate quantity; MERLIN vẫn là hệ thống quyết định cuối cùng.

Associate Copilot nằm ở boundary riêng, không kết nối với POS hoặc ordering. Với thông tin food-safety, hệ thống chỉ hiển thị exact approved evidence cùng citation; không cho LLM tự tạo, diễn giải hoặc dịch nội dung an toàn.

Câu chuyển

The next question is whether this architecture can finish safely before the immovable 04:00 deadline.

Slide 4 — End-to-end nightly batch

Thời gian: 65 giây

The batch starts at 22:00. Validation must finish by 22:20, statistical forecasting by 00:20 and deterministic optimization by 01:20.

No new retry begins after 01:30. At 01:45, every required partition, model version, ruleset, constraint, checksum and audit record must form one complete signed manifest.

The certified adapter can publish only between 01:45 and 02:00. At 02:00 all AI writes close, leaving MERLIN two hours for generation, native review and EDI.

Any late, incomplete, stale, uncertain or failed result becomes no override. A recovery at 03:30 is retained only for diagnosis; it cannot restart the current run.

The 02:00 gate is still a proposal. It requires measured MERLIN P99 of 90 minutes or less; otherwise we move the gate earlier.

Ba mốc cần nhớ

- **01:30:** Stop starting new retries.
- **01:45:** Complete-set gate.
- **02:00:** Absolute AI write close.

Fail-open không có nghĩa là gì?

Fail-open không có nghĩa:

AI lỗi rồi MERLIN cố gắng chờ hoặc retry thêm.

Fail-open có nghĩa:

AI lỗi thì AI tự rút khỏi run hiện tại, còn MERLIN tiếp tục.

Một số failure behavior:

Tình huống	AI sidecar	MERLIN
Snapshot quá 24 giờ	Bypass scope	Tiếp tục
Completeness dưới 99.5%	Quarantine/bypass	Tiếp tục
Missing partition lúc 01:45	Publish nothing	Tiếp tục
Confidence thấp	Suppress row	Dừng min/max
Epoch hoặc permit hết hạn	Reject transaction	Tiếp tục
AI phục hồi lúc 03:30	Chỉ lưu diagnosis	Không rerun

Điểm quan trọng nhất:

MERLIN never waits for AI.

Luồng batch, fail-open và disable flow đều được mô tả thành các gate có thể kiểm thử, thay vì chỉ tuyên bố chung rằng hệ thống “highly available”.

Câu chuyển

The timeline protects continuity, but production also requires quantified capacity, quality and cost evidence.

Slide 5 — Quantified NFR and cost check

Thời gian: 65 giây

These figures are design targets and release gates, not benchmark results.

At normal volume, the system must produce 27 million forecasts and optimize 7.04 million stocked candidates each night. The conservative six-times test is 162 million forecasts and 42.24 million optimizations. At 30,000 forecasts per second and 15,000 optimizations per second, the forecast and optimization stages require approximately 90 and 47 minutes.

The total target path is 198.7 minutes within a 240-minute window, leaving 41.3 minutes of calculated headroom.

Business targets are out-of-stock from 7.2 to 3 percent, waste from 4.8 to 3 percent and WAPE from 41 to 25 percent or less.

Annual cost targets 3.8 million dollars, with a four-million-dollar hard ceiling. Every figure still requires measured proof.

Ý nghĩa của các con số

27M forecasts và 7.04M optimizations

Không phải cả 27 triệu forecast đều tạo override.

- **27M:** số forecast cho các store-SKU-time combinations.
- **7.04M:** stocked candidates đủ điều kiện đi qua optimization.
- Chỉ một phần rất nhỏ sau suppression và cap mới có thể được ghi vào override table.

Six-times volume

Stress test sử dụng:

- 162M forecasts.
- 42.24M optimizations.
- Ba lần chạy liên tiếp thành công.

Đây là volume bảo thủ dành cho peak, chẳng hạn Lunar New Year hoặc promotion lớn.

Storage

Giả định 1.2 KB cho mỗi forecast record:

- Normal run: 32.4 GB.
- Six-times run: 194.4 GB.

Đây mới là **per-run planning assumption**, chưa phải retention cost hoàn chỉnh. Chính sách retention cho AI artifact vẫn là production gate.

Inventory accuracy 78%

Có khoảng 22% dữ liệu inventory có khả năng sai.

Với 7.04M stocked candidates:

$$7.04\text{M} \times 22\% = \text{khoảng } 1.5488\text{M candidates có thể không chính xác.}$$

Vì vậy inventory không được dùng như một point value tuyệt đối. Mỗi candidate cần:

- Data age.
- Confidence interval.
- Feasibility ở cả lower và upper bound.
- Quantity caps.
- Suppression khi không đủ tin cậy.

Targets, not results

Không nói:

“The system can already process 162 million forecasts.”

Phải nói:

“The production gate requires three consecutive tests at 162 million forecasts.”

NFR table liên kết mỗi requirement với target, calculation, failure behavior, monitoring metric, warning threshold, critical threshold và owner.

Câu chuyển

With the constraints and NFRs defined, we can now explain why we selected this technology direction.

Slide 6 — Technology selection and ADR

Thời gian: 55 giây

We used a reproducible weighted matrix rather than selecting technologies by preference.

For integration, the external asynchronous sidecar scores 4.80 because it provides the strongest legacy isolation, fail-open continuity, supported-interface fit and rollback.

For execution, managed elastic batch scores 4.65 because it best fits the deadline and conservative six-times scale.

For forecasting, hybrid hierarchical statistical ML scores 4.55 because of promotion handling, uncertainty output and sparse-series sharing. However, when cost receives more weight, hybrid and one global model tie at 4.45. Therefore replay evidence, not the matrix alone, decides the final model.

The ADR records this decision and its costs: duplicate snapshots, reconciliation, certified adapter work and two-system operations.

Technology matrix dùng để làm gì?

Matrix trả lời:

“Trong các option có thể chọn, direction nào phù hợp nhất với constraints?”

Ba quyết định:

Decision	Lựa chọn	Score
MERLIN integration	External asynchronous sidecar	4.80
Execution platform	Managed elastic batch	4.65
Model strategy	Hybrid hierarchical statistical ML	4.55

Mỗi tiêu chí có trọng số và mỗi option được chấm từ 1 đến 5.

Điểm mạnh của matrix là có **sensitivity analysis**:

- Sidecar vẫn đứng đầu khi thay đổi trọng số.
- Managed batch vẫn đứng đầu khi tăng trọng số operability.
- Hybrid và global model có thể hòa 4.45 khi cost quan trọng hơn.

Điều đó cho thấy nhóm không xem 4.55 là “chân lý toán học”. Model cuối cùng vẫn phụ thuộc replay benchmark.

No LLM được xem xét cho numeric forecast hoặc replenishment quantity vì các quyết định này yêu cầu:

- Reproducibility.
- High throughput.
- Calibrated uncertainty.
- Cost khoảng \$0.0004 trên mỗi forecast.
- Version-controlled model và rules.

Technology-selection matrix chọn direction nhưng không tự cấp quyền production.

ADR dùng để làm gì?

ADR trả lời câu hỏi khác:

“Quyết định kiến trúc chính thức là gì, vì sao quyết định như vậy, và chúng ta chấp nhận hậu quả nào?”

ADR-001 ghi nhận:

- Context.
- Decision drivers.
- Options considered.
- Selected decision.
- Positive consequences.
- Negative consequences.
- Rollback.
- Conditions to revisit.

Trạng thái của ADR là:

Accepted for replay and shadow; production influence remains gated.

Matrix so sánh lựa chọn; ADR biến lựa chọn thành quyết định kiến trúc có accountability và điều kiện xem xét lại.

Câu chuyển

Even with the selected architecture, five risks remain above our tolerance for unbounded production influence.

Slide 7 — Top-five architecture risks

Thời gian: 45 giây

We score inherent risk as likelihood multiplied by impact, before controls.

The top risks are deadline failure and inaccurate inventory, both scoring 20; peak capacity and model degradation at 16; and legacy integrity and food-safety liability at 15.

Each risk has a measurable tripwire and a safe response. For example, inventory interval coverage below 85 percent suppresses the affected scope. Forecast throughput below 22,500 per second disables the model or slice. Any stale commit or manual-row change kills influence. Any generated safety display is an immediate failure.

The response is always bypass, suppression or disablement—never a desperate late retry.

Cách đọc một risk row

Mỗi risk có bốn phần:

1. **Cause:** Điều gì có thể xảy ra?
2. **Mitigation:** Làm gì trước để giảm likelihood hoặc impact?
3. **Critical threshold:** Khi nào phải dừng?
4. **Contingency:** Sau khi vượt threshold, hệ thống chuyển về trạng thái nào?

Ví dụ R-01:

- Risk: batch hoặc MERLIN chạy quá lâu.
- Critical: reserve dưới 30 phút hoặc có AI write sau 02:00.
- Response: publish nothing.
- Authoritative outcome: MERLIN tiếp tục.

Top five:

Risk	Score	Safe fallback
Deadline	20	Bypass AI
Inventory quality	20	Suppress row/scope
Peak/model	16	Disable model hoặc slice
Legacy adapter integrity	15	Abort, revoke và shadow
Food-safety/legal	15	Refuse, disable và escalate

Data residency, cost, review fatigue và provider outage không bị bỏ qua. Chúng có score thấp hơn 15 nên được quản lý trong NFR table thay vì chiếm một trong năm vị trí top risk.

Câu chuyển

Because these risks cannot be removed on paper, the system must earn production influence gradually.

Slide 8 — Rollout and kill switch

Thời gian: 50 giây

The sidecar earns influence in stages.

Discovery certifies interfaces, timing and transaction behavior. Historical replay proves forecast quality, uncertainty, six-times capacity, cost and failure handling. Production shadow then runs for at least four representative weeks with zero MERLIN writes.

Only after every gate passes may the pilot cover 20 stores, two low-risk non-fresh categories, no more than 5,000 rows within the measured adapter cap and at most 100 reviews per night.

The kill switch acknowledges within 30 seconds, rejects new writes within 60 seconds and verifies safe within five minutes using deny-default epochs, short permits, independent SAP revocation and exact-row cleanup.

Our final test is simple: remove the sidecar, and MERLIN still orders.

Rollout không phải migration khỏi MERLIN

Các giai đoạn:

1. Discovery.
2. Historical replay.
3. Shadow ít nhất bốn tuần.
4. Pilot 20 stores.
5. Bounded expansion.

Trong tất cả các giai đoạn:

- MERLIN vẫn authoritative.
- Chỉ sử dụng ba supported interfaces.
- Không có parallel order master.
- Không có kế hoạch dần thay thế MERLIN.

Pilot boundaries

Pilot chỉ cho phép:

- 20 stores.
- Hai low-risk non-fresh categories.
- Không quá `min(5,000, measured adapter cap)` rows/night.
- Tối đa hai case packs cho mỗi store-SKU, hoặc cap thấp hơn.
- Tối đa 100 review items mỗi đêm.

Kill switch

Kill switch không chỉ là một nút bật/tắt ở UI.

Luồng thực tế:

1. Duty Manager tạo epoch mới ở trạng thái `DISABLING`.
2. Hệ thống ngừng phát short-lived permits.
3. Adapter kiểm tra epoch ngay bên trong transaction.
4. New writes bị reject trong 60 giây.
5. Nếu adapter không phản hồi, SAP break-glass identity revoke network/database access và terminate sessions.
6. Cleanup identity chỉ xóa exact unconsumed AI-owned rows.
7. Manual rows không bao giờ bị chọn.
8. `VERIFIED_SAFE` phải đạt trong năm phút.

Các drill như stale epoch, check/write race, adapter compromise, missing acknowledgement và cleanup failure phải được kiểm thử. Một drill thất bại đồng nghĩa hệ thống tiếp tục ở shadow mode.

4. Giải thích chi tiết từng artifact

A1 — C4 Context, Container and Narrated Flows

Các file

- 03-c4-context.mmd
- 04-c4-container.mmd
- 05-request-and-batch-flows.md

Mục đích

A1 trả lời ba câu hỏi:

1. Ai tương tác với hệ thống?
2. Các system hoặc container được phân tách như thế nào?
3. Dữ liệu chạy theo luồng nào và failure được xử lý ra sao?

C4 Context Diagram

Context diagram thể hiện:

- Category Manager.
- Store Associate.
- Replenishment Operations.
- MERLIN.
- POS.
- AI sidecar.
- Associate Copilot.
- Suppliers.
- Approved content.
- Weather/event data.
- Loyalty PII boundary.

Điểm quan trọng không chỉ là các đường nối xuất hiện, mà còn là những đường nối **không tồn tại**:

- Không có AI → POS.
- Không có AI → EDI.
- Không có AI → Supplier.
- Không có Copilot → Ordering.
- Loyalty PII không được export trong Release 1.

C4 Container Diagram

Container diagram zoom sâu hơn vào AI sidecar:

- Snapshot validation.
- Statistical forecast ML.
- Deterministic optimizer.

- Certified adapter.
- Disable control.
- Append-only audit.

Nó cũng thể hiện legacy containers:

- Nightly batch.
- Override table.
- MERLIN engine.
- Review queue.
- EDI connector.

Đường dashed từ review queue về adapter chỉ mang:

- Order ID.
- Current quantity.
- Correlation key.

Đây là **post-generation evidence**, không phải dependency cần để MERLIN tạo order.

Narrated Flow

Narrated flow bổ sung những thứ sơ đồ tĩnh không thể hiện rõ:

- Timeline.
- Exit gates.
- Failure behavior.
- Retry policy.
- Disable flow.
- Review capacity.
- Copilot safety behavior.

A1 chứng minh kiến trúc không chỉ “trông hợp lý trên diagram”, mà có runtime semantics rõ ràng.

A2 — Quantified NFR Table

File

- `07-nfr-table.md`

Mục đích

A2 biến các từ chung chung như:

- Fast.
- Scalable.
- Safe.
- Reliable.
- Affordable.

thành các điều kiện đo được.

Ví dụ:

Không nói:

“The batch must be fast.”

Mà nói:

Forecast throughput phải đạt ít nhất 30,000 records/s trong test; dưới 22,500 records/s là critical.

Không nói:

“The kill switch must work quickly.”

Mà nói:

Acknowledge trong 30 giây, reject new writes trong 60 giây và verified safe trong năm phút.

Cấu trúc mỗi NFR

Mỗi dòng có:

- Requirement.
- Target.
- Proposed mechanism.
- Calculation.
- Failure behavior.
- Monitoring metric.
- Warning threshold.
- Critical threshold.
- Owner.

Điểm này rất quan trọng vì nó nối architecture với operations.

NFR quan trọng nhất khi trình bày

Ưu tiên năm nhóm:

1. Deadline và 04:00.
2. 27M normal và 6x peak.
3. Inventory quality và business outcomes.
4. Fail-open cùng legacy boundaries.
5. Cost và rollout limits.

Các NFR khác như copilot, residency, retention và food safety vẫn quan trọng nhưng không đủ thời gian để đọc toàn bộ trên sân khấu.

A3 — Technology-Selection Matrix

File

- 10-technology-selection-matrix.md

Mục đích

A3 chứng minh lựa chọn không dựa trên:

- Công nghệ đang phổ biến.
- Sở thích cá nhân.
- “Cloud-native is always better.”
- “AI means LLM.”

Ba quyết định được tách riêng vì chúng giải quyết ba vấn đề khác nhau:

1. Cách tích hợp với MERLIN.
2. Nền tảng thực thi batch.
3. Chiến lược forecast model.

Sensitivity analysis

Sensitivity analysis đặc biệt quan trọng trong Q&A.

Khi trọng số thay đổi:

- Sidecar vẫn thắng.
- Managed batch vẫn thắng.
- Model hybrid có thể hòa global model.

Điều này cho phép trả lời trung thực:

Chúng tôi đã chọn architecture boundary, nhưng chưa giả vờ rằng model family đã được chứng minh. Replay benchmark sẽ quyết định model cuối cùng.

A4 — Architecture Decision Record

File

- 11-adr.md

Mục đích

ADR là bản ghi chính thức của quyết định:

Deploy an asynchronous fail-open sidecar while MERLIN remains authoritative.

ADR không phải bản tóm tắt architecture diagram. Nó ghi:

- Vì sao cần quyết định.
- Những option đã xem xét.
- Vì sao reject option khác.
- Hậu quả tích cực.
- Hậu quả tiêu cực.
- Rollback.
- Khi nào cần revisit.

Điểm mạnh của ADR này

ADR không chỉ liệt kê benefit. Nó chấp nhận rõ:

- Duplicate snapshots.
- Reconciliation.
- SAP certification.
- Two-system monitoring.
- On-call cost.
- Bounded value.

Đây là dấu hiệu của trade-off thật, thay vì “fake trade-off” chỉ liệt kê những bất tiện nhỏ.

A5 — Top-Five Risk Register

File

- `12-risk-register.md`

Mục đích

A5 trả lời:

Những lý do nào có thể khiến kiến trúc bị từ chối?

Risk score là:

$\text{Likelihood} \times \text{Impact}$

Đây là **inherent risk trước controls**, không phải residual risk sau mitigation.

Tại sao chỉ có năm risk?

Artifact dùng threshold 15.

Những risk dưới 15 vẫn được quản lý trong NFR nhưng không nằm trong top five. Việc giới hạn năm risk buộc team tập trung vào những vấn đề có thể:

- Làm trễ order.
- Tạo quantity sai ở quy mô lớn.

- Làm hỏng MERLIN.
- Gây food-safety liability.

Phân biệt mitigation và contingency

Mitigation

Giảm khả năng risk xảy ra, ví dụ:

- Deadline gates.
- Calibrated intervals.
- Certified adapter.
- Load testing.

Contingency

Hành động sau khi threshold bị vượt, ví dụ:

- Bypass AI.
- Suppress scope.
- Disable model.
- Revoke access.
- Refuse and escalate.

A6 — Variant B Legacy Assessment and Retrofit Plan

File

- `13-variant-b-artifact.md`

Mục đích

A6 là artifact đặc trưng nhất của Variant B. Nó chứng minh nhóm hiểu “AI Retrofit” không phải là:

- Viết lại hệ thống legacy.
- Tạo một order engine mới song song.
- Chèn LLM vào MERLIN.
- Tạo thêm interface vì integration hiện tại bất tiện.

A6 xác định:

- Legacy authority.
- Supported interfaces.
- Changeable components.
- Immutable components.
- Unsafe areas.
- Integration pattern.
- Fail-open semantics.
- Kill switch.
- Shadow rollout.

- Review model.
- Rollback.
- Accountability.

Acceptance test cuối cùng

Câu kết luận mạnh nhất của toàn bài là:

Remove the sidecar and MERLIN still orders.

Câu này thể hiện đồng thời:

- Fail-open.
- Loose coupling.
- Rollback.
- Business continuity.
- Legacy authority.
- Retrofit thay vì replacement.

5. Các câu tuyệt đối không nên nói

Không nên nói	Nên nói
AI generates supplier orders	AI produces bounded recommendations; MERLIN generates orders
We use real-time inventory	We use a nightly snapshot with 78% inventory accuracy
The system processes 162M forecasts	Production requires three consecutive 162M test passes
The annual cost is \$3.8M	\$3.8M is the target; \$4M is the hard ceiling
The architecture is production-ready	It is approved for discovery, replay and shadow only
The hybrid model is definitely best	The matrix selects it provisionally; replay evidence makes the final choice
The kill switch deletes override rows	It removes only exact, unconsumed AI-owned rows
The LLM decides replenishment quantities	Statistical ML forecasts; deterministic rules constrain quantities
AI may retry when it recovers at 03:30	Late recovery is diagnosis only; the current run remains closed
MERLIN depends on the sidecar	MERLIN never waits for AI

6. Q&A preparation

Question 1: Why did you choose 02:00 as the AI close?

02:00 is a proposed gate, not an assumed fact. It is valid only if measured MERLIN P99 is 90 minutes or less, leaving at least 30 minutes before the fixed 04:00 deadline. If measurement does not support that reserve, the AI close moves earlier and the full flow is retested.

Question 2: How can you trust recommendations when inventory is only 78% accurate?

We do not treat inventory as exact shelf truth. Every influenced row requires data age and a calibrated interval. The deterministic optimizer tests feasibility at both bounds, applies case-pack and category caps, and suppresses the row when confidence or interval coverage is insufficient.

Question 3: Is 162 million forecasts realistic?

It is a conservative six-times release test, not a measured result. Production influence requires three consecutive passes at the required throughput, with complete partitions, reproducible versions, acceptable cost and no missed deadline gate.

Question 4: Why not connect AI synchronously to MERLIN?

A synchronous dependency would allow AI latency or failure to delay replenishment. The asynchronous sidecar uses the three supported interfaces and can disappear without changing MERLIN's ordering path.

Question 5: Why use hybrid hierarchical ML instead of one global model?

The weighted matrix gives hybrid a small advantage for promotion behaviour, sparse-series sharing and calibrated uncertainty. However, sensitivity analysis produces a tie when cost receives more weight, so replay evidence decides the final model.

Question 6: What happens when AI returns at 03:30?

Nothing changes in the current run. The output is retained for diagnosis and future learning only. There is no late publication, no sidecar EDI and no rerun that could threaten the 04:00 deadline.

Question 7: Is the kill switch realistic if the cloud control fails?

The design has an independent SAP break-glass path. If normal acknowledgement fails, a separate identity revokes database and network access and terminates sessions. Cleanup uses an exact AI-owned ledger and never selects manual rows.

Question 8: Why include an associate copilot in this architecture?

It is a separate read-only capability and does not participate in ordering. Safety content follows a deterministic exact-evidence path. Optional language generation is limited to eligible non-safety requests and cannot generate, paraphrase or translate safety content.

7. Closing statement

We are not asking the business to trust AI because the architecture looks modern.

We are asking for permission to measure it safely through replay and shadow. MERLIN remains authoritative, every production influence is bounded, every critical risk has a numeric tripwire, and every failure returns to the incumbent replenishment path.

Remove the sidecar, and MERLIN still orders.