

KỊCH BẢN TRÌNH BÀY TIẾNG VIỆT

VARIANT B — AI RETROFIT

1. Câu chuyện tổng thể

Không nên trình bày sáu artifact như sáu tài liệu rời rạc. Toàn bộ bài trình bày cần đi theo một chuỗi lập luận thống nhất:

Ràng buộc → Kiến trúc → Luồng vận hành → NFR định lượng → Quyết định công nghệ → Rủi ro → Triển khai có kiểm soát

Thông điệp trung tâm:

Giữ MERLIN toàn quyền kiểm soát; cho phép AI thất bại mà không làm gián đoạn việc giao hàng.

Điều này có nghĩa:

- Không thay thế MERLIN.
- Không đưa AI vào critical path của quy trình đặt hàng.
- AI chỉ tạo đề xuất có giới hạn.
- MERLIN vẫn tạo mọi đơn hàng.
- Chỉ MERLIN được gửi EDI đến nhà cung cấp.
- AI lỗi, trễ, thiếu dữ liệu hoặc bị vô hiệu hóa thì quy trình min/max hiện tại vẫn tiếp tục.

2. Dàn bài 8 slide trong 7 phút

Slide	Nội dung	Artifact	Thời gian
1	Thông điệp điều hành và nguyên tắc thiết kế	Tổng hợp	30 giây
2	Đánh giá hệ thống legacy	A6	50 giây
3	C4 Context và Container Architecture	A1	60 giây
4	Luồng batch ban đêm và fail-open	A1	65 giây
5	NFR, capacity, business target và cost	A2	65 giây
6	Technology-selection matrix và ADR	A3, A4	55 giây
7	Top-five architecture risks	A5	45 giây
8	Rollout, kill switch và kết luận	A6	50 giây
Tổng cộng			420 giây

3. Script trình bày chi tiết

Slide 1 — Thông điệp chính

Thời gian: 30 giây

Xin chào mọi người.

Nguyên tắc thiết kế của nhóm chúng tôi rất đơn giản: giữ MERLIN toàn quyền kiểm soát, đồng thời cho phép AI thất bại mà không làm gián đoạn hoạt động giao hàng.

Chúng tôi không thay thế MERLIN. Thay vào đó, chúng tôi bổ sung một AI sidecar hoạt động độc lập và bất đồng bộ. Sidecar sử dụng mô hình thống kê để dự báo nhu cầu và các quy tắc xác định để tạo đề xuất bổ sung hàng có giới hạn.

MERLIN vẫn là hệ thống tạo mọi đơn hàng và là hệ thống duy nhất gửi EDI đến nhà cung cấp. Nếu AI không tạo được kết quả hợp lệ, quy trình min/max hiện tại của MERLIN vẫn tiếp tục không thay đổi.

Cách nhấn giọng

Nhấn mạnh ba câu:

- “Chúng tôi không thay thế MERLIN.”
- “MERLIN vẫn tạo mọi đơn hàng.”
- “AI có thể thất bại mà việc giao hàng vẫn tiếp tục.”

Câu chuyển

Để hiểu tại sao chúng tôi chọn thiết kế này, trước tiên cần xác định rõ hệ thống legacy cho phép chúng ta thay đổi những gì.

Slide 2 — Đánh giá hệ thống legacy

Thời gian: 50 giây

Variant B bắt đầu từ các ràng buộc của hệ thống hiện tại, không bắt đầu từ việc lựa chọn công nghệ.

Những thành phần chúng ta có thể thay đổi gồm AI sidecar bên ngoài, các adapter hẹp đã được chứng nhận, hệ thống monitoring, audit và cơ chế vô hiệu hóa.

Những thành phần không thể thay đổi gồm MERLIN engine, quyền tạo đơn hàng của MERLIN, hệ thống POS, định dạng EDI cố định và thời hạn 04:00.

Ngoài ra, có những khu vực không an toàn để can thiệp như các bảng MERLIN chưa được tài liệu hóa, scheduler nội bộ, các dòng dữ liệu được nhập thủ công và việc xem số lượng inventory hiện tại như sự thật tuyệt đối trên kệ hàng.

Vì vậy, giải pháp chỉ sử dụng đúng ba điểm mở rộng được hỗ trợ: nightly snapshot, override table trước khi tạo đơn và review queue sau khi MERLIN tạo đơn. Chúng tôi không tự tạo ra một interface thứ tư.

Ý nghĩa của ba điểm mở rộng

1. Nightly snapshot

AI nhận một bản snapshot chỉ đọc vào ban đêm.

AI không truy vấn trực tiếp POS hoặc các bảng nội bộ của MERLIN.

2. Override table

AI có thể ghi các đề xuất có giới hạn vào bảng override trước khi MERLIN chạy order generation.

3. Post-generation review queue

Sau khi MERLIN tạo đơn hàng, queue có thể trả về:

- Order ID.
- Số lượng MERLIN đã tạo.
- Correlation key.

Thông tin này chỉ dùng cho review, correlation và audit.

Điểm quan trọng

Không nên nói:

“Chúng tôi sẽ xây thêm API để kết nối thuận tiện hơn.”

Phải nói:

“Kiến trúc chỉ được phép sử dụng ba interface đã được legacy system hỗ trợ.”

Câu chuyển

Với những boundary này, AI phải được đặt bên cạnh MERLIN, không được đặt bên trong MERLIN.

Slide 3 — C4 Context và Container Architecture

Thời gian: 60 giây

Ở cấp độ Context, MERLIN vẫn là hệ thống có thẩm quyền đối với toàn bộ quy trình đặt hàng. Category Manager tiếp tục sử dụng quy trình review gốc của MERLIN, còn nhà cung cấp chỉ nhận EDI do MERLIN gửi.

Trong AI sidecar, nightly snapshot trước tiên được kiểm tra schema, độ mới, completeness, checksum và data residency. Sau đó mô hình thống kê tạo demand forecast, quantile và confidence interval.

Một deterministic optimizer tiếp tục áp dụng các ràng buộc về case pack, shelf life, inventory interval, năng lực distribution centre và category cap.

Chỉ certified adapter mới được phép ghi các dòng dữ liệu giới hạn của run hiện tại vào override table. MERLIN đọc các dòng này, chạy engine không thay đổi và tự tạo đơn hàng.

AI không có bất kỳ đường kết nối nào đến POS, EDI hoặc nhà cung cấp. Dữ liệu trả về sau khi MERLIN tạo đơn chỉ là bằng chứng phục vụ correlation và audit, không phải runtime dependency.

Trình tự giải thích sơ đồ

Trình bày từ trái sang phải:

1. Nightly snapshot.
2. Validation.
3. Statistical forecast ML.
4. Deterministic optimizer.
5. Certified adapter.
6. Override table.
7. MERLIN engine.
8. Review queue.
9. EDI và supplier.

Statistical Forecast ML làm gì?

Mô hình thống kê chỉ dự báo nhu cầu, ví dụ:

- Expected demand.
- Lower demand quantile.
- Upper demand quantile.
- Confidence interval.
- Promotion demand.

Mô hình không trực tiếp đặt hàng.

Deterministic Optimizer làm gì?

Optimizer chuyển forecast thành candidate quantity hợp lệ dựa trên các quy tắc cố định:

- Số lượng phải theo nguyên case pack.
- Không được vượt giới hạn shelf life.
- Không được vượt năng lực DC.
- Không được vượt category cap.
- Phải khả thi tại cả lower và upper inventory bound.

Điểm cần nhấn mạnh:

Statistical ML dự báo nhu cầu. Deterministic rules giới hạn số lượng. MERLIN mới là hệ thống tạo order.

Associate Copilot

Associate Copilot được tách riêng hoàn toàn khỏi POS và ordering.

Đối với nội dung food-safety:

- Chỉ hiển thị exact approved evidence.
- Có fixed approved wording.
- Có citation và source version.
- Không cho LLM tự tạo, tóm tắt, dịch hoặc diễn giải nội dung an toàn.

Câu chuyển

Sau khi xác định được kiến trúc, câu hỏi tiếp theo là liệu toàn bộ quy trình có thể hoàn thành an toàn trước thời hạn cố định 04:00 hay không.

Slide 4 — Luồng batch ban đêm và fail-open

Thời gian: 65 giây

Quy trình batch bắt đầu lúc 22:00. Validation phải hoàn thành trước 22:20. Forecasting phải hoàn thành trước 00:20 và deterministic optimization trước 01:20.

Sau 01:30, hệ thống không được bắt đầu retry mới. Tại 01:45, tất cả partition, model version, ruleset, constraint, checksum và audit record bắt buộc phải tạo thành một complete signed manifest.

Certified adapter chỉ được phép publish trong khoảng từ 01:45 đến 02:00. Đúng 02:00, toàn bộ AI write phải đóng lại, để MERLIN có hai giờ thực hiện order generation, native review và gửi EDI trước 04:00.

Bất kỳ kết quả nào bị trễ, thiếu, cũ, không chắc chắn hoặc không hợp lệ đều trở thành không có override. Nếu AI phục hồi lúc 03:30, kết quả chỉ được giữ lại để chẩn đoán và không được restart run hiện tại.

Mốc 02:00 hiện mới là proposed gate. Nó chỉ hợp lệ nếu MERLIN P99 được đo thực tế không quá 90 phút. Nếu không đạt, AI write close phải được chuyển sớm hơn.

Ba mốc bắt buộc phải nhớ

01:30 — Retry stop

Không được bắt đầu retry mới.

Mục đích là ngăn hệ thống cố gắng cứu một run đã quá muộn.

01:45 — Complete-set gate

Toàn bộ dữ liệu phải đầy đủ và nhất quán.

Thiếu một partition bắt buộc nghĩa là:

Publish nothing.

02:00 — Absolute write close

Sau 02:00:

- Không được ghi override mới.
- Không retry transaction.
- Không phục hồi run.
- Không có late publication.

Fail-open nghĩa là gì?

Fail-open không có nghĩa:

AI gặp lỗi nhưng MERLIN phải chờ AI xử lý.

Fail-open có nghĩa:

AI gặp lỗi thì AI rút khỏi run hiện tại, còn MERLIN vẫn tiếp tục quy trình mặc định.

Một số tình huống failure

Tình huống	Sidecar xử lý	Kết quả authoritative
Snapshot cũ hơn 24 giờ	Bypass phạm vi ảnh hưởng	MERLIN tiếp tục
Completeness dưới 99.5%	Quarantine hoặc bypass	MERLIN tiếp tục
Thiếu partition lúc 01:45	Publish nothing	MERLIN tiếp tục
Confidence thấp	Suppress row	MERLIN dùng min/max
Permit hết hạn	Reject transaction	MERLIN tiếp tục
Epoch không hợp lệ	Abort hoặc rollback	MERLIN tiếp tục
AI phục hồi lúc 03:30	Chỉ lưu để diagnosis	Không rerun

Thông điệp quan trọng nhất:

MERLIN không bao giờ phải chờ AI.

Luồng batch, fail-open và disable flow đều được định nghĩa bằng các gate có thể kiểm thử.

Câu chuyện

Timeline giúp bảo vệ tính liên tục, nhưng để được phép ảnh hưởng production, kiến trúc còn phải chứng minh capacity, quality và cost bằng số liệu.

Slide 5 — NFR định lượng và kiểm tra chi phí

Thời gian: 65 giây

Các con số trên slide là design target và release gate, chưa phải kết quả benchmark đã đo.

Ở tải thông thường, hệ thống cần tạo 27 triệu forecast và tối ưu 7.04 triệu stocked candidate mỗi đêm. Bài kiểm tra bảo thủ ở mức sáu lần tải là 162 triệu forecast và 42.24 triệu optimization.

Với throughput mục tiêu 30.000 forecast mỗi giây và 15.000 optimization mỗi giây, forecasting cần khoảng 90 phút và optimization cần khoảng 47 phút.

Tổng thời gian target là 198.7 phút trong cửa sổ 240 phút, để lại 41.3 phút headroom theo tính toán.

Business target gồm giảm out-of-stock từ 7.2% xuống 3%, giảm fresh waste từ 4.8% xuống 3% và giảm WAPE từ 41% xuống không quá 25%.

Chi phí mục tiêu là khoảng 3.8 triệu đô mỗi năm, với hard ceiling là 4 triệu đô. Tất cả các con số này vẫn phải được chứng minh bằng benchmark và observed production evidence.

27M forecast và 7.04M optimization

Không phải cả 27 triệu forecast đều trở thành override.

- 27M là tổng số forecast record.
- 7.04M là số stocked candidate được đưa vào optimization.
- Chỉ một phần nhỏ sau validation, suppression và cap mới có thể được publish.

Six-times peak

Six-times test gồm:

- 162M forecasts.
- 42.24M optimizations.
- Ba lần chạy liên tiếp thành công.

Bài test này đại diện cho các giai đoạn cao điểm như:

- Lunar New Year.
- Promotion lớn.

- Tăng mạnh số lượng store hoặc SKU.

Tính toán throughput

Forecast stage:

$$162.000.000 \div 30.000 = 5.400 \text{ giây} = 90 \text{ phút.}$$

Optimization stage:

$$42.240.000 \div 15.000 = 2.816 \text{ giây} \approx 46.93 \text{ phút.}$$

Storage assumption

Giả định mỗi forecast record là 1.2 KB:

- Normal run: 32.4 GB.
- Six-times run: 194.4 GB.

Đây là storage trên mỗi run.

Nó chưa bao gồm retention policy dài hạn, vì retention cho AI artifacts vẫn phải được Data Governance phê duyệt.

Inventory accuracy chỉ 78%

Khoảng 22% inventory record có thể không chính xác.

Với 7.04M stocked pairs:

$$7.04M \times 22\% = \text{khoảng } 1.5488M \text{ candidate có thể sai.}$$

Vì vậy inventory phải được xử lý như một khoảng không chắc chắn, không phải một con số tuyệt đối.

Mỗi candidate cần:

- Data age.
- Calibrated interval.
- Interval coverage.
- Feasibility ở lower và upper bound.
- Quantity cap.
- Suppression khi không đủ tin cậy.

Phân biệt target và result

Không được nói:

“Hệ thống đã xử lý được 162 triệu forecast.”

Nên nói:

“Production gate yêu cầu hệ thống vượt qua ba lần test liên tiếp với 162 triệu forecast.”

NFR table ánh xạ từng requirement với target, calculation, failure behavior, metric, warning threshold, critical threshold và owner.

Câu chuyển

Khi constraints và NFR đã được xác định, chúng tôi mới bắt đầu lựa chọn integration pattern, execution platform và model strategy.

Slide 6 — Technology-selection matrix và ADR

Thời gian: 55 giây

Chúng tôi sử dụng weighted decision matrix có thể tái lập, thay vì chọn công nghệ dựa trên sở thích.

Đối với integration pattern, external asynchronous sidecar đạt 4.80 điểm vì bảo vệ legacy tốt nhất, hỗ trợ fail-open, phù hợp với các interface hiện có và có khả năng rollback rõ ràng.

Đối với execution platform, managed elastic batch đạt 4.65 điểm vì phù hợp nhất với deadline và six-times scale.

Đối với forecast model, hybrid hierarchical statistical ML đạt 4.55 điểm nhờ khả năng xử lý promotion, sparse series và uncertainty output. Tuy nhiên, khi tăng trọng số cho cost, hybrid và global model cùng đạt 4.45 điểm. Vì vậy model cuối cùng phải được quyết định bằng replay evidence, không chỉ bằng matrix.

ADR chính thức ghi nhận quyết định fail-open sidecar và các trade-off được chấp nhận như duplicate snapshot, reconciliation, certified adapter và vận hành hai hệ thống.

Decision 1 — Integration pattern

Lựa chọn	Điểm
External asynchronous sidecar	4.80
Event-driven boundary	2.95
Synchronous API gateway	1.80
In-process MERLIN plugin	1.30

Sidecar thắng vì:

- Không thay đổi MERLIN core.
- Không đưa AI vào synchronous critical path.
- Dễ shadow.
- Dễ rollback.

- Có thể disable độc lập.

Decision 2 — Execution platform

Lựa chọn	Điểm
Managed elastic batch	4.65
Kubernetes batch workers	4.15
Managed Spark	3.90
Fixed on-premises compute	3.10

Managed elastic batch được ưu tiên vì:

- Có thể scale theo partition.
- Hỗ trợ deadline-aware orchestration.
- Phù hợp với nightly workload.
- Có khả năng chạy six-times test.

Trade-off:

- Provider dependency.
- Cost variability.
- Data-transfer và residency control.
- Phải có quota và pre-peak reservation.

Decision 3 — Model strategy

Lựa chọn	Điểm
Hybrid hierarchical statistical ML	4.55
One global statistical model	4.35
Classical baseline	3.50
Per-store-SKU model	3.20

Hybrid có lợi thế về:

- Sparse series.
- Promotion behaviour.
- Hierarchical information sharing.
- Quantile và uncertainty.

Tuy nhiên sensitivity analysis cho thấy khi tăng cost weight:

Hybrid và global model cùng đạt 4.45.

Do đó nhóm không tuyên bố hybrid chắc chắn tốt nhất.

Replay phải đo:

- Enterprise WAPE.
- Promotion WAPE.
- Interval calibration.
- Throughput.
- Cost.
- Operability.

Tại sao không dùng LLM?

Không có LLM trong numeric forecasting hoặc replenishment optimization vì yêu cầu:

- Reproducibility.
- Throughput lớn.
- Version control.
- Calibrated uncertainty.
- Cost thấp.
- Kết quả số có thể audit.

Technology-selection matrix chọn hướng kiến trúc nhưng không chứng minh production readiness.

ADR là gì?

ADR ghi lại quyết định kiến trúc chính thức:

Triển khai một asynchronous fail-open AI sidecar, trong khi MERLIN vẫn là order authority.

ADR bao gồm:

- Context.
- Decision drivers.
- Options considered.
- Decision.
- Positive consequences.
- Negative consequences.
- Risks.
- Rollback.
- Conditions to revisit.

Trạng thái hiện tại là:

Accepted for replay and shadow; production influence remains gated.

Matrix giúp so sánh các lựa chọn.

ADR biến lựa chọn đó thành quyết định có accountability và điều kiện xem xét lại.

Câu chuyện

Mặc dù đã chọn được kiến trúc, vẫn còn năm rủi ro có mức độ quá cao để cho phép AI ảnh hưởng production mà không có giới hạn.

Slide 7 — Top-five architecture risks

Thời gian: 45 giây

Chúng tôi tính inherent risk bằng likelihood nhân impact, trước khi áp dụng control.

Hai rủi ro cao nhất là deadline failure và inaccurate inventory, cùng đạt 20 điểm. Peak capacity và model degradation đạt 16 điểm. Legacy integrity và food-safety liability cùng đạt 15 điểm.

Mỗi risk đều có numeric tripwire và safe fallback. Ví dụ, nếu inventory interval coverage dưới 85%, phạm vi tương ứng sẽ bị suppress. Nếu forecast throughput dưới 22.500 record mỗi giây, model hoặc slice sẽ bị disable. Bất kỳ stale commit hoặc thay đổi manual row nào đều lập tức dừng influence.

Response luôn là bypass, suppress hoặc disable. Chúng tôi không cho phép retry tuyệt vọng khi đã gần 04:00.

Top five risk

Risk	Score	Critical response
Deadline và operations	20	Bypass AI
Inventory quality	20	Suppress row hoặc scope
Peak load và model quality	16	Disable model hoặc slice
Legacy adapter integrity	15	Abort, revoke và shadow
Food-safety và legal	15	Refuse, disable và escalate

R-01 — Deadline

Nguyên nhân:

- MERLIN P99 chưa được đo.
- Batch sáu lần tải có thể chạy lâu.
- Retry hoặc DB lock có thể tiêu thụ reserve.

Critical trigger:

- AI write sau 02:00.
- Reserve dưới 30 phút.
- MERLIN phải chờ AI.
- EDI hoàn thành sau 04:00.

Safe response:

Publish nothing; MERLIN tiếp tục.

R-02 — Inventory

Nguyên nhân:

- Inventory chỉ chính xác 78%.
- Snapshot có thể cũ đến 24 giờ.

Critical trigger:

- Interval coverage dưới 85%.
- Không có confidence interval.
- Data age trên 24 giờ.
- Completeness dưới 99.5%.
- Quantity vượt cap.

Safe response:

Suppress row hoặc scope.

R-03 — Model và capacity

Critical trigger:

- Enterprise WAPE trên 30%.
- Promotion WAPE trên 45%.
- Forecast dưới 22.500 record/s.
- Optimizer dưới 11.733 record/s.
- Cost vượt 4 triệu đô mỗi năm.

Safe response:

Disable model hoặc slice; quay về MERLIN.

R-04 — Legacy integrity

Critical trigger:

- Stale epoch commit.
- Manual row bị thay đổi.
- New write vẫn xảy ra sau 60 giây.
- MERLIN phải chờ.
- Cleanup không chứng minh được an toàn trong năm phút.

Safe response:

Abort hoặc rollback, revoke SAP access và quay về shadow.

R-05 — Food-safety

Critical trigger:

- Generated safety content.
- Wrong-SKU content.
- Unsupported content.
- Invalid signature.
- Universal refusal.
- Escalation acknowledgement quá năm phút.

Safe response:

Refuse, disable affected domain và escalate.

Data residency, cost, review fatigue và provider outage vẫn được kiểm soát trong NFR table nhưng có risk score thấp hơn 15.

Câu chuyển

Vì các risk này không thể được loại bỏ chỉ bằng thiết kế trên giấy, AI phải từng bước chứng minh rằng nó xứng đáng được phép ảnh hưởng đến production.

Slide 8 — Rollout và kill switch

Thời gian: 50 giây

AI sidecar phải từng bước giành được quyền ảnh hưởng.

Giai đoạn Discovery dùng để chứng nhận interface, timing, transaction behaviour và cleanup. Historical replay dùng để kiểm tra forecast quality, uncertainty, six-times capacity, cost và failure behaviour.

Sau đó production shadow phải chạy ít nhất bốn tuần đại diện với số lượng MERLIN write bằng không. Chỉ khi toàn bộ gate được vượt qua, pilot mới được phép triển khai tại 20 cửa hàng, hai category non-fresh có rủi ro thấp, tối đa 5.000 dòng trong giới hạn adapter đã đo và không quá 100 review mỗi đêm.

Kill switch phải acknowledge trong 30 giây, reject write mới trong 60 giây và xác nhận trạng thái an toàn trong năm phút bằng deny-default epoch, short permit, independent SAP revocation và exact-row cleanup.

Acceptance test cuối cùng rất đơn giản: tháo AI sidecar ra và MERLIN vẫn tiếp tục đặt hàng.

Các giai đoạn rollout

1. Discovery

Chứng nhận:

- Supported interfaces.
- MERLIN timing.
- Override table semantics.
- Review queue fields.
- Transaction và locking.
- Ownership.
- Cleanup.

2. Historical replay

Đo:

- Forecast WAPE.
- Promotion performance.
- Interval calibration.
- Six-times throughput.
- Storage.
- Cost.
- Failure drills.

3. Production shadow

Điều kiện:

- Chạy tối thiểu bốn tuần đại diện.
- Bao gồm promotion period.
- Không ghi bất kỳ dòng nào vào MERLIN.
- Vẫn chạy đầy đủ validation, forecast, optimization và audit.

4. Bounded pilot

Giới hạn:

- 20 stores.
- Hai low-risk non-fresh categories.
- Tối đa `min(5.000, measured adapter cap)` rows/night.
- Tối đa hai case pack cho mỗi store-SKU hoặc cap thấp hơn.
- Tối đa 100 review item mỗi đêm.

5. Bounded expansion

Chỉ được mở rộng khi:

- Quality gate tiếp tục đạt.
- Không có critical incident.
- Cost nằm trong ceiling.

- Operational roster đã được tài trợ.
- Kill-switch drill tiếp tục thành công.

Kill switch hoạt động như thế nào?

Bước 1

Duty Manager tạo epoch mới với trạng thái:

DISABLING

Bước 2

Permit issuance dừng ngay lập tức.

Adapter và access gateway phải acknowledge trong 30 giây.

Bước 3

Adapter kiểm tra lại epoch ngay bên trong transaction.

Mọi stale work phải:

- Abort.
- Hoặc rollback.

New write phải bị reject trong 60 giây.

Bước 4

Nếu adapter không acknowledge:

- SAP break-glass identity revoke DB access.
- Revoke network access.
- Terminate active sessions.

Bước 5

Một cleanup identity riêng chỉ xóa:

- Exact unconsumed AI-owned keys.
- Các dòng được xác định bằng exact key và hash ledger.

Không được chọn manual row.

Bước 6

Trong năm phút phải chứng minh:

- Không còn active permit.
- Không còn active session.
- Không còn active transaction.

- Không có unexplained AI row.

Trạng thái cuối:

VERIFIED_SAFE

Trong toàn bộ quá trình:

- MERLIN vẫn chạy.
- Native review vẫn chạy.
- EDI vẫn chạy.

Rollout plan, kill-switch requirement và giới hạn pilot được định nghĩa trong Variant B artifact.

4. Giải thích từng artifact

A1 — C4 Context, Container và Narrated Flows

File

- 03-c4-context.mmd
- 04-c4-container.mmd
- 05-request-and-batch-flows.md

Artifact này trả lời điều gì?

A1 trả lời ba câu hỏi:

1. Những actor và system nào tham gia?
2. Boundary giữa AI và legacy nằm ở đâu?
3. Runtime flow và failure flow hoạt động như thế nào?

Context diagram

C4 Context cho thấy:

- Category Manager.
- Store Associate.
- Replenishment Operations.
- MERLIN.
- POS.
- AI sidecar.
- Associate Copilot.
- Supplier.
- Approved product content.
- Weather hoặc event data.

Điểm quan trọng nhất là các kết nối không tồn tại:

- Không có AI → POS.
- Không có AI → EDI.
- Không có AI → Supplier.
- Không có Copilot → Ordering.
- Không export member-level loyalty PII.

Container diagram

Container diagram phân rã sidecar thành:

- Snapshot Validator.
- Feature Pipeline.
- Statistical Forecast Service.
- Deterministic Optimizer.
- Certified Adapter.
- Control và Kill Switch.
- Immutable Audit Ledger.

Phía legacy gồm:

- MERLIN nightly batch.
- Override table.
- MERLIN engine.
- Review queue.
- EDI sender.

Narrated flow

Narrated flow bổ sung những yếu tố mà diagram tĩnh không thể hiện:

- Timeline.
- Retry policy.
- Exit gate.
- Failure behaviour.
- Review semantics.
- Disable flow.
- Copilot safety behaviour.

A1 chứng minh rằng kiến trúc không chỉ đúng về component mà còn có behaviour rõ ràng khi hệ thống lỗi.

A2 — Quantified NFR Table

File

- `07-nfr-table.md`

Artifact này trả lời điều gì?

A2 trả lời:

Kiến trúc phải đạt những điều kiện định lượng nào trước khi được phép influence production?

NFR không chỉ ghi “system must be scalable”.

NFR phải xác định:

- Bao nhiêu record?
- Trong bao lâu?
- Metric nào?
- Warning threshold là gì?
- Critical threshold là gì?
- Khi thất bại thì hệ thống làm gì?
- Ai chịu trách nhiệm?

Các nhóm NFR chính

1. Deadline 04:00.
2. Normal và six-times capacity.
3. Forecast quality và business outcome.
4. Fail-open và kill switch.
5. MERLIN, POS và EDI boundaries.
6. Copilot latency và usefulness.
7. Food-safety.
8. Data quality, residency và retention.
9. Cost và margin.
10. Bounded influence và operational support.

A2 là cầu nối giữa kiến trúc và production operations.

A3 — Technology-Selection Matrix

File

- 10-technology-selection-matrix.md

Artifact này trả lời điều gì?

A3 trả lời:

Trong các option khả thi, lựa chọn nào phù hợp nhất với constraints?

Matrix sử dụng:

Weighted total = tổng của weight × score, chia cho 100.

Mỗi option được chấm từ 1 đến 5.

Vì sao phải có sensitivity analysis?

Sensitivity analysis giúp kiểm tra:

Kết quả có phải chỉ thắng vì team cố tình chọn trọng số có lợi hay không?

Kết quả:

- Sidecar vẫn thắng khi chuyển trọng số sang cost.
- Managed batch vẫn thắng khi tăng trọng số operability.
- Hybrid model có thể hòa global model.

Điều này làm quyết định minh bạch và tránh bias.

A4 — Architecture Decision Record

File

- 11-adr.md

Artifact này trả lời điều gì?

A4 trả lời:

Quyết định kiến trúc chính thức là gì và nhóm chấp nhận những hậu quả nào?

Quyết định:

Sử dụng external asynchronous fail-open AI sidecar; MERLIN vẫn authoritative.

Positive consequences

- MERLIN tiếp tục khi AI lỗi.
- POS và EDI được cô lập.
- AI có thể scale độc lập.
- Shadow chạy trên flow thực tế.
- Có thể remove sidecar mà không rollback MERLIN code.

Negative consequences

- Duplicate snapshot.
- Reconciliation.
- Certified SAP adapter.
- Hai hệ thống monitoring.
- On-call và operating cost.
- Giá trị AI bị giới hạn có chủ đích.

Một ADR tốt phải ghi cả negative consequence, không chỉ benefit.

A5 — Top-Five Risk Register

File

- 12-risk-register.md

Artifact này trả lời điều gì?

A5 trả lời:

Những vấn đề nào có thể khiến kiến trúc bị từ chối?

Risk score:

Likelihood × Impact.

Mỗi risk phải có:

- Cause.
- Likelihood.
- Impact.
- Score.
- Mitigation.
- Contingency.
- Monitoring signal.
- Numeric threshold.
- Risk owner.

Mitigation và contingency khác nhau thế nào?

Mitigation

Hành động trước khi sự cố xảy ra:

- Deadline gate.
- Confidence interval.
- Load testing.
- Certified adapter.

Contingency

Hành động khi critical threshold đã bị vượt:

- Bypass AI.
- Suppress scope.
- Disable model.
- Revoke access.
- Refuse và escalate.

A6 — Variant B Legacy Assessment and Retrofit Plan

File

- 13-variant-b-artifact.md

Artifact này trả lời điều gì?

A6 trả lời:

Làm thế nào để bổ sung AI vào hệ thống legacy mà không thay thế hoặc phá vỡ hệ thống hiện tại?

Artifact này xác định:

- Legacy authority.
- Supported extension points.
- Những gì có thể thay đổi.
- Những gì không được thay đổi.
- Những gì không an toàn để can thiệp.
- Fail-open behaviour.
- Kill switch.
- Shadow rollout.
- Human review.
- Rollback.
- Production gates.
- Accountability.

Vì sao A6 đặc trưng cho Variant B?

Variant B là AI Retrofit.

Nó không phải:

- Replatform toàn bộ MERLIN.
- Thay thế order engine.
- Xây parallel order master.
- Chèn LLM vào core system.
- Tạo synchronous dependency mới.

Variant B thêm intelligence ở boundary được hỗ trợ và giữ nguyên authority của legacy system.

Acceptance test cuối cùng:

Tháo sidecar ra và MERLIN vẫn tiếp tục đặt hàng.

5. Những câu không nên nói trong phần trình bày

Không nên nói	Nên nói
AI tạo supplier order	AI tạo bounded recommendation; MERLIN tạo order
Chúng tôi sử dụng real-time inventory	Chúng tôi dùng nightly snapshot với độ chính xác inventory 78%
Hệ thống xử lý được 162M forecast	Production yêu cầu ba lần test liên tiếp ở mức 162M
Chi phí là 3.8 triệu đô	3.8 triệu là target; 4 triệu là hard ceiling
Kiến trúc đã production-ready	Kiến trúc mới được chấp nhận cho replay và shadow
Hybrid model chắc chắn tốt nhất	Hybrid đang được ưu tiên; replay sẽ quyết định model cuối cùng
Kill switch xoá toàn bộ override	Kill switch chỉ xoá exact unconsumed AI-owned rows
LLM quyết định số lượng order	Statistical ML forecast; deterministic rules constrain quantity
AI có thể chạy lại lúc 03:30	03:30 chỉ phục vụ diagnosis, không được rerun
MERLIN phụ thuộc vào AI	MERLIN không bao giờ phải chờ AI

6. Chuẩn bị Q&A

Câu 1: Tại sao chọn 02:00 làm AI write close?

02:00 hiện mới là proposed gate. Mốc này chỉ được sử dụng nếu MERLIN P99 đo thực tế không quá 90 phút, để còn tối thiểu 30 phút reserve trước 04:00. Nếu không đủ reserve, write close phải được chuyển sớm hơn và toàn bộ flow phải được retest.

Câu 2: Inventory chỉ chính xác 78%, vậy làm sao tin recommendation?

Chúng tôi không xem inventory như shelf truth tuyệt đối. Mỗi candidate phải có data age và calibrated interval. Optimizer kiểm tra feasibility tại cả hai đầu interval và áp dụng case-pack, shelf-life, DC và category cap. Khi uncertainty quá cao, row bị suppress và MERLIN dùng kết quả mặc định.

Câu 3: 162 triệu forecast có thực tế không?

Đây là six-times release test bảo thủ, chưa phải kết quả đã đạt. Production influence chỉ được phép sau ba lần test liên tiếp đáp ứng throughput, completeness, reproducibility, cost và deadline gate.

Câu 4: Tại sao không kết nối AI synchronously với MERLIN?

Vì synchronous dependency khiến AI latency hoặc failure có thể làm chậm ordering. External asynchronous sidecar sử dụng ba interface được hỗ trợ và có thể bị remove mà không ảnh hưởng đến MERLIN.

Câu 5: Tại sao chọn hybrid hierarchical model?

Matrix cho hybrid lợi thế nhỏ về promotion, sparse series và uncertainty. Tuy nhiên sensitivity analysis tạo ra kết quả hòa với global model khi cost có trọng số cao hơn. Vì vậy replay evidence sẽ quyết định model cuối cùng.

Câu 6: Điều gì xảy ra khi AI phục hồi lúc 03:30?

Không có thay đổi nào đối với run hiện tại. Kết quả chỉ được lưu để diagnosis và learning. Không có late publication, không rerun và không có sidecar EDI.

Câu 7: Kill switch có thực tế không nếu cloud control bị lỗi?

Có một independent SAP break-glass path. Nếu normal acknowledgement thất bại, một identity riêng có thể revoke database và network access, đồng thời terminate session. Cleanup chỉ sử dụng exact AI-owned ledger và không chạm manual row.

Câu 8: Tại sao associate copilot xuất hiện trong kiến trúc?

Copilot là capability read-only độc lập, không liên quan đến ordering. Nội dung food-safety sử dụng deterministic exact-evidence path. LLM chỉ có thể hỗ trợ các câu hỏi non-safety đủ điều kiện và không được tạo hoặc diễn giải nội dung an toàn.

7. Câu kết thúc đề xuất

Chúng tôi không yêu cầu doanh nghiệp tin tưởng AI chỉ vì kiến trúc này sử dụng công nghệ hiện đại.

Chúng tôi chỉ đề xuất cho phép AI chứng minh giá trị một cách an toàn thông qua replay và shadow. MERLIN vẫn giữ toàn bộ quyền quyết định, mọi production influence đều bị giới hạn, mọi critical risk đều có numeric tripwire, và mọi failure đều quay về incumbent replenishment path.

Acceptance test cuối cùng rất đơn giản: tháo AI sidecar ra và MERLIN vẫn tiếp tục đặt hàng.